

# TrabalhoLSTM

May 21, 2021

## 0.1 Modelo Futuros Mini Ethereum - Dados Históricos

O Mercado Futuro é o ambiente onde você pode ganhar com a alta ou baixa de um determinado ativo, seja ele uma commodity (Milho, Café, Boi Gordo), uma moeda (como o dólar), um Índice (Bovespa, Índice S&P 500) ou mesmo uma taxa de juros. Nele, são negociados contratos futuros.

O mini índice é um contrato futuro derivado do Índice Ethereum, ou seja, é um ativo que tem como base o sobe e desce desse índice. Como esse tipo de operação envolve **risco considerável** e **oscilações frequentes no mercado**, ela é indicada apenas para aqueles que se encaixam no perfil de investidor arrojado.

Neste trabalho iremos implementar uma RNNs para realizar a predição diária do Mini Índice da Ibovespa.

O dataset “**FuturosMiniEthereum.csv**” possui informações dispostas em colunas :

- **Date:** Data das operações na bolsa (diária)
- **Close:** Valor de Fechamento do Índice da Ibovespa (no dia)
- **Open:** Valor da Abertura do Índice da Ibovespa (no dia)
- **High:** Valor máximo do Índice da Ibovespa (no dia)
- **Low:** Valor mínimo do Índice da Ibovespa (no dia)
- **Vol:** Volume de contratos negociados (no dia)

### 0.1.1 Bibliotecas

```
[1]: import pandas as pd
from keras.models import Sequential
from keras.layers import Dense, Dropout, LSTM
import plotly.graph_objects as go
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
```

### 0.1.2 Carregando os dados

Vamos começar lendo o arquivo FuturosMiniBovespa.csv em um dataframe do pandas, mas antes vamos dar uma olhadinha no gráfico de variação do último mês do índice Ibovespa.

```
[2]: DataSet=pd.read_csv('FuturosEthereum-teste.csv')
```

```
[3]: fig = go.Figure(data=[go.Candlestick(x=DataSet['Date'],
                                         open=DataSet['Open'], high=DataSet['High'],
                                         low=DataSet['Low'], close=DataSet['Close'])
                                         ])

fig.update_layout(xaxis_rangeslider_visible=False)
fig.show()
```

## 0.2 Rede Neural Recorrente (RNN)

Antes de avançar para LSTM, primeiro vamos introduzir o conceito de Redes Recorrentes. Elas são redes utilizadas para reconhecer padrões quando os resultados do passado influenciam no resultado atual. Um exemplo disso são as séries temporais, em que a ordem dos dados é muito importante.

Nesta arquitetura, um neurônio tem como entrada seu estado anterior, além das entradas da camada anterior. A imagem abaixo ilustra esta nova modelagem.

Observe que H representa o estado. Assim, no estado H\_1, o neurônio recebe como parâmetro de entrada X\_1 e, além disso, seu estado anterior H\_0. O principal problema desta arquitetura é que os estados mais antigos são esquecidos muito rapidamente. Ou seja, para sequências em que precisamos lembrar além de um passado imediato, as redes RNNs são limitadas.

### 0.2.1 Rede LSTM

Uma rede LSTM tem origem em uma RNN (Rede Neural Recorrente). Mas ela resolve o problema de memória mudando sua arquitetura.

Nesta nova arquitetura, cada neurônio possui 3 gates, cada um com uma função diferente. São eles:  
\* Input Gate \* Output Gate \* Forget Gate

Agora, um neurônio LSTM recebe entradas de seu estado anterior, assim como ocorria na Rede Recorrente:

### 0.2.2 Agora vamos ler o arquivo do período desejável

```
[4]: DataSet=pd.read_csv('FuturosEthereum-treino.csv')
DataSet=DataSet.dropna()
DataSet.head()
```

```
[4]:
```

	Date	Open	High	Low	Close	Adj Close	Volume
0	2015-08-07	2.831620	3.536610	2.521120	2.772120	2.772120	164329.0
1	2015-08-08	2.793760	2.798810	0.714725	0.753325	0.753325	674188.0
2	2015-08-09	0.706136	0.879810	0.629191	0.701897	0.701897	532170.0
3	2015-08-10	0.713989	0.729854	0.636546	0.708448	0.708448	405283.0
4	2015-08-11	0.708087	1.131410	0.663235	1.067860	1.067860	1463100.0

```
[5]: DataSet.describe()
```

```
[5]:
```

	Open	High	...	Adj Close	Volume
count	2090.000000	2090.000000	...	2090.000000	2.090000e+03
mean	308.398014	319.833590	...	309.636474	6.075951e+09
std	425.797837	443.141785	...	429.030976	8.970136e+09
min	0.431589	0.482988	...	0.434829	1.021280e+05
25%	13.185075	13.531575	...	13.176775	3.173252e+07
50%	189.438515	196.909904	...	189.644058	1.972050e+09
75%	359.281754	371.925491	...	359.041008	8.570984e+09
max	2757.734131	2797.972412	...	2773.207031	6.073363e+10


[8 rows x 6 columns]

### 0.2.3 Inicialmente iremos criar uma RNN baseada apenas no Valor de Abertura

```
[6]: plt.scatter(DataSet['Date'],DataSet['Open'],)
plt.show()

base_treinamento = DataSet.iloc[:, 1:2].values

#DataSet.drop(['Date','Close','High','Low','Volume'],axis=1,inplace=True)
```



```
[8]: base_treinamento
```

```
[8]: array([[2.83162000e+00],
           [2.79376000e+00],
```

```
[7.06136000e-01],  
...,  
[2.66468555e+03],  
[2.74864966e+03],  
[2.75773413e+03]])
```

#### 0.2.4 Normalizar os dados do Mini Índice

```
[9]: from sklearn.preprocessing import MinMaxScaler  
scaler=MinMaxScaler(feature_range=(0,1))  
DataScaled=scaler.fit_transform(base_treinamento)
```

```
[10]: print(DataScaled)
```

```
[[8.70427152e-04]  
 [8.56696341e-04]  
 [9.95708653e-05]  
 ...  
 [9.66253763e-01]  
 [9.96705304e-01]  
 [1.00000000e+00]]
```

#### 0.2.5 Definição dos previsores

```
[18]: previsores = []  
preco_real = []  
NRecurso = 90  
DataSetLen = len(DataScaled)  
print(DataSetLen)
```

2090

```
[19]: for i in range(NRecurso, DataSetLen):  
    previsores.append(DataScaled[i-NRecurso:i,0])  
    preco_real.append(DataScaled[i,0])  
  
previsores, preco_real = np.array(previsores), np.array(preco_real)
```

```
[20]: previsores.shape
```

```
[20]: (2000, 90)
```

### 0.2.6 Tranformar para o formato do Tensor do Keras

```
[21]: previsoires = np.reshape(previsoires, (previsoires.shape[0], previsoires.shape[1],  
→1))
```

```
[22]: previsoires.shape
```

```
[22]: (2000, 90, 1)
```

### 0.2.7 Estrutura da Rede Neural

```
[ ]:
```

```
[23]: # Camada de entrada  
regressor = Sequential()  
regressor.add(LSTM(units = 100, return_sequences = True, input_shape =  
→(previsoires.shape[1], 1)))  
regressor.add(Dropout(0.3))  
  
# Cada Oculta 1  
regressor.add(LSTM(units = 50, return_sequences = True))  
regressor.add(Dropout(0.3))  
  
# Cada Oculta 2  
regressor.add(LSTM(units = 50, return_sequences = True))  
regressor.add(Dropout(0.3))  
  
# Cada Oculta 3  
regressor.add(LSTM(units = 50))  
regressor.add(Dropout(0.3))  
  
# Camada de Saída  
regressor.add(Dense(units = 1, activation = 'linear'))
```

### 0.2.8 Construindo a Rede

```
[24]: regressor.compile(optimizer = 'rmsprop', loss = 'mean_squared_error',  
→metrics = ['mean_absolute_error'])  
regressor.fit(previsoires, preco_real, epochs = 100, batch_size = 32)
```

Epoch 1/100

63/63 [=====] - 18s 182ms/step - loss: 0.0106 -  
mean\_absolute\_error: 0.0587

Epoch 2/100

63/63 [=====] - 11s 181ms/step - loss: 0.0032 -  
mean\_absolute\_error: 0.0332

Epoch 3/100

```

63/63 [=====] - 11s 176ms/step - loss: 0.0027 -
mean_absolute_error: 0.0317
Epoch 4/100
63/63 [=====] - 11s 173ms/step - loss: 0.0026 -
mean_absolute_error: 0.0285
Epoch 5/100
63/63 [=====] - 11s 176ms/step - loss: 0.0022 -
mean_absolute_error: 0.0284
Epoch 6/100
63/63 [=====] - 11s 176ms/step - loss: 0.0020 -
mean_absolute_error: 0.0280
Epoch 7/100
63/63 [=====] - 12s 184ms/step - loss: 0.0020 -
mean_absolute_error: 0.0256
Epoch 8/100
63/63 [=====] - 12s 184ms/step - loss: 0.0021 -
mean_absolute_error: 0.0266
Epoch 9/100
63/63 [=====] - 12s 183ms/step - loss: 0.0016 -
mean_absolute_error: 0.0252
Epoch 10/100
63/63 [=====] - 12s 184ms/step - loss: 0.0019 -
mean_absolute_error: 0.0246
Epoch 11/100
63/63 [=====] - 11s 181ms/step - loss: 0.0012 -
mean_absolute_error: 0.0222
Epoch 12/100
63/63 [=====] - 11s 175ms/step - loss: 0.0016 -
mean_absolute_error: 0.0228
Epoch 13/100
63/63 [=====] - 11s 178ms/step - loss: 0.0016 -
mean_absolute_error: 0.0235
Epoch 14/100
63/63 [=====] - 11s 179ms/step - loss: 0.0014 -
mean_absolute_error: 0.0227
Epoch 15/100
63/63 [=====] - 11s 176ms/step - loss: 0.0012 -
mean_absolute_error: 0.0206
Epoch 16/100
63/63 [=====] - 11s 176ms/step - loss: 0.0013 -
mean_absolute_error: 0.0212
Epoch 17/100
63/63 [=====] - 11s 176ms/step - loss: 0.0010 -
mean_absolute_error: 0.0206
Epoch 18/100
63/63 [=====] - 11s 178ms/step - loss: 0.0010 -
mean_absolute_error: 0.0197
Epoch 19/100

```

```

63/63 [=====] - 11s 177ms/step - loss: 0.0012 -
mean_absolute_error: 0.0204
Epoch 20/100
63/63 [=====] - 11s 175ms/step - loss: 0.0011 -
mean_absolute_error: 0.0206
Epoch 21/100
63/63 [=====] - 11s 176ms/step - loss: 0.0013 -
mean_absolute_error: 0.0207
Epoch 22/100
63/63 [=====] - 11s 175ms/step - loss: 9.3160e-04 -
mean_absolute_error: 0.0189
Epoch 23/100
63/63 [=====] - 11s 174ms/step - loss: 9.6013e-04 -
mean_absolute_error: 0.0185
Epoch 24/100
63/63 [=====] - 11s 178ms/step - loss: 0.0012 -
mean_absolute_error: 0.0201
Epoch 25/100
63/63 [=====] - 11s 176ms/step - loss: 9.7575e-04 -
mean_absolute_error: 0.0194
Epoch 26/100
63/63 [=====] - 11s 175ms/step - loss: 0.0010 -
mean_absolute_error: 0.0187
Epoch 27/100
63/63 [=====] - 11s 177ms/step - loss: 0.0011 -
mean_absolute_error: 0.0195
Epoch 28/100
63/63 [=====] - 11s 177ms/step - loss: 0.0012 -
mean_absolute_error: 0.0211
Epoch 29/100
63/63 [=====] - 11s 178ms/step - loss: 0.0011 -
mean_absolute_error: 0.0186
Epoch 30/100
63/63 [=====] - 11s 181ms/step - loss: 7.8500e-04 -
mean_absolute_error: 0.0185
Epoch 31/100
63/63 [=====] - 11s 176ms/step - loss: 9.8730e-04 -
mean_absolute_error: 0.0187
Epoch 32/100
63/63 [=====] - 11s 176ms/step - loss: 0.0011 -
mean_absolute_error: 0.0199
Epoch 33/100
63/63 [=====] - 11s 173ms/step - loss: 0.0010 -
mean_absolute_error: 0.0189
Epoch 34/100
63/63 [=====] - 11s 173ms/step - loss: 0.0013 -
mean_absolute_error: 0.0195
Epoch 35/100

```

```

63/63 [=====] - 11s 174ms/step - loss: 9.8068e-04 -
mean_absolute_error: 0.0176
Epoch 36/100
63/63 [=====] - 11s 175ms/step - loss: 9.2939e-04 -
mean_absolute_error: 0.0185
Epoch 37/100
63/63 [=====] - 11s 175ms/step - loss: 0.0012 -
mean_absolute_error: 0.0194
Epoch 38/100
63/63 [=====] - 11s 174ms/step - loss: 9.6969e-04 -
mean_absolute_error: 0.0182
Epoch 39/100
63/63 [=====] - 11s 173ms/step - loss: 8.2974e-04 -
mean_absolute_error: 0.0172
Epoch 40/100
63/63 [=====] - 11s 175ms/step - loss: 8.5349e-04 -
mean_absolute_error: 0.0174
Epoch 41/100
63/63 [=====] - 12s 184ms/step - loss: 9.1215e-04 -
mean_absolute_error: 0.0182
Epoch 42/100
63/63 [=====] - 12s 187ms/step - loss: 8.4554e-04 -
mean_absolute_error: 0.0177
Epoch 43/100
63/63 [=====] - 12s 184ms/step - loss: 0.0011 -
mean_absolute_error: 0.0192
Epoch 44/100
63/63 [=====] - 12s 184ms/step - loss: 8.3003e-04 -
mean_absolute_error: 0.0178
Epoch 45/100
63/63 [=====] - 11s 180ms/step - loss: 8.7891e-04 -
mean_absolute_error: 0.0176
Epoch 46/100
63/63 [=====] - 11s 181ms/step - loss: 8.5457e-04 -
mean_absolute_error: 0.0181
Epoch 47/100
63/63 [=====] - 11s 179ms/step - loss: 8.8883e-04 -
mean_absolute_error: 0.0176
Epoch 48/100
63/63 [=====] - 11s 172ms/step - loss: 7.1617e-04 -
mean_absolute_error: 0.0170
Epoch 49/100
63/63 [=====] - 11s 177ms/step - loss: 7.4395e-04 -
mean_absolute_error: 0.0163
Epoch 50/100
63/63 [=====] - 11s 173ms/step - loss: 8.0962e-04 -
mean_absolute_error: 0.0160
Epoch 51/100

```



63/63 [=====] - 11s 173ms/step - loss: 8.9467e-04 -  
mean\_absolute\_error: 0.0171  
Epoch 52/100  
63/63 [=====] - 11s 173ms/step - loss: 9.1947e-04 -  
mean\_absolute\_error: 0.0180  
Epoch 53/100  
63/63 [=====] - 11s 171ms/step - loss: 7.5348e-04 -  
mean\_absolute\_error: 0.0174  
Epoch 54/100  
63/63 [=====] - 11s 172ms/step - loss: 0.0010 -  
mean\_absolute\_error: 0.0180  
Epoch 55/100  
63/63 [=====] - 11s 171ms/step - loss: 8.4986e-04 -  
mean\_absolute\_error: 0.0172  
Epoch 56/100  
63/63 [=====] - 11s 177ms/step - loss: 7.0141e-04 -  
mean\_absolute\_error: 0.0167  
Epoch 57/100  
63/63 [=====] - 11s 174ms/step - loss: 7.7178e-04 -  
mean\_absolute\_error: 0.0165  
Epoch 58/100  
63/63 [=====] - 11s 178ms/step - loss: 8.0533e-04 -  
mean\_absolute\_error: 0.0172  
Epoch 59/100  
63/63 [=====] - 11s 177ms/step - loss: 7.3314e-04 -  
mean\_absolute\_error: 0.0165  
Epoch 60/100  
63/63 [=====] - 11s 177ms/step - loss: 7.0981e-04 -  
mean\_absolute\_error: 0.0161  
Epoch 61/100  
63/63 [=====] - 11s 177ms/step - loss: 6.7033e-04 -  
mean\_absolute\_error: 0.0157  
Epoch 62/100  
63/63 [=====] - 11s 177ms/step - loss: 7.7409e-04 -  
mean\_absolute\_error: 0.0160  
Epoch 63/100  
63/63 [=====] - 11s 177ms/step - loss: 7.0291e-04 -  
mean\_absolute\_error: 0.0157  
Epoch 64/100  
63/63 [=====] - 11s 179ms/step - loss: 8.6078e-04 -  
mean\_absolute\_error: 0.0171  
Epoch 65/100  
63/63 [=====] - 12s 183ms/step - loss: 9.4839e-04 -  
mean\_absolute\_error: 0.0178  
Epoch 66/100  
63/63 [=====] - 11s 181ms/step - loss: 5.9985e-04 -  
mean\_absolute\_error: 0.0158  
Epoch 67/100

63/63 [=====] - 12s 186ms/step - loss: 6.8990e-04 -  
mean\_absolute\_error: 0.0164  
Epoch 68/100  
63/63 [=====] - 11s 181ms/step - loss: 8.1053e-04 -  
mean\_absolute\_error: 0.0164  
Epoch 69/100  
63/63 [=====] - 11s 176ms/step - loss: 7.3680e-04 -  
mean\_absolute\_error: 0.0160  
Epoch 70/100  
63/63 [=====] - 11s 175ms/step - loss: 8.0002e-04 -  
mean\_absolute\_error: 0.0161  
Epoch 71/100  
63/63 [=====] - 11s 175ms/step - loss: 7.6728e-04 -  
mean\_absolute\_error: 0.0158  
Epoch 72/100  
63/63 [=====] - 11s 175ms/step - loss: 7.9832e-04 -  
mean\_absolute\_error: 0.0162  
Epoch 73/100  
63/63 [=====] - 11s 176ms/step - loss: 7.4304e-04 -  
mean\_absolute\_error: 0.0164  
Epoch 74/100  
63/63 [=====] - 11s 181ms/step - loss: 6.9806e-04 -  
mean\_absolute\_error: 0.0159  
Epoch 75/100  
63/63 [=====] - 11s 178ms/step - loss: 7.9505e-04 -  
mean\_absolute\_error: 0.0165  
Epoch 76/100  
63/63 [=====] - 11s 179ms/step - loss: 6.8144e-04 -  
mean\_absolute\_error: 0.0159  
Epoch 77/100  
63/63 [=====] - 11s 175ms/step - loss: 7.8674e-04 -  
mean\_absolute\_error: 0.0162  
Epoch 78/100  
63/63 [=====] - 11s 175ms/step - loss: 7.3630e-04 -  
mean\_absolute\_error: 0.0158  
Epoch 79/100  
63/63 [=====] - 11s 172ms/step - loss: 5.9120e-04 -  
mean\_absolute\_error: 0.0156  
Epoch 80/100  
63/63 [=====] - 10s 166ms/step - loss: 7.6319e-04 -  
mean\_absolute\_error: 0.0161  
Epoch 81/100  
63/63 [=====] - 11s 167ms/step - loss: 9.2105e-04 -  
mean\_absolute\_error: 0.0170  
Epoch 82/100  
63/63 [=====] - 11s 171ms/step - loss: 6.3826e-04 -  
mean\_absolute\_error: 0.0158  
Epoch 83/100

```

63/63 [=====] - 11s 175ms/step - loss: 7.0190e-04 -
mean_absolute_error: 0.0156
Epoch 84/100
63/63 [=====] - 11s 173ms/step - loss: 7.9875e-04 -
mean_absolute_error: 0.0166
Epoch 85/100
63/63 [=====] - 11s 174ms/step - loss: 7.7809e-04 -
mean_absolute_error: 0.0162
Epoch 86/100
63/63 [=====] - 11s 175ms/step - loss: 6.4176e-04 -
mean_absolute_error: 0.0147
Epoch 87/100
63/63 [=====] - 11s 178ms/step - loss: 7.2543e-04 -
mean_absolute_error: 0.0153
Epoch 88/100
63/63 [=====] - 11s 179ms/step - loss: 8.3206e-04 -
mean_absolute_error: 0.0163
Epoch 89/100
63/63 [=====] - 11s 177ms/step - loss: 7.9672e-04 -
mean_absolute_error: 0.0157
Epoch 90/100
63/63 [=====] - 11s 173ms/step - loss: 7.2527e-04 -
mean_absolute_error: 0.0155
Epoch 91/100
63/63 [=====] - 11s 174ms/step - loss: 7.6337e-04 -
mean_absolute_error: 0.0156
Epoch 92/100
63/63 [=====] - 11s 174ms/step - loss: 5.4174e-04 -
mean_absolute_error: 0.0143
Epoch 93/100
63/63 [=====] - 11s 174ms/step - loss: 8.3118e-04 -
mean_absolute_error: 0.0164
Epoch 94/100
63/63 [=====] - 11s 178ms/step - loss: 5.6554e-04 -
mean_absolute_error: 0.0144
Epoch 95/100
63/63 [=====] - 11s 175ms/step - loss: 6.7491e-04 -
mean_absolute_error: 0.0144
Epoch 96/100
63/63 [=====] - 11s 180ms/step - loss: 6.5369e-04 -
mean_absolute_error: 0.0161
Epoch 97/100
63/63 [=====] - 11s 175ms/step - loss: 5.4592e-04 -
mean_absolute_error: 0.0152
Epoch 98/100
63/63 [=====] - 11s 175ms/step - loss: 6.7181e-04 -
mean_absolute_error: 0.0155
Epoch 99/100

```

```
63/63 [=====] - 11s 173ms/step - loss: 7.1616e-04 -
mean_absolute_error: 0.0154
Epoch 100/100
63/63 [=====] - 11s 177ms/step - loss: 7.2076e-04 -
mean_absolute_error: 0.0162
```

[24]: <tensorflow.python.keras.callbacks.History at 0x7fd1f5b2b950>

## 0.2.9 Conjunto de dados para o Teste

```
[25]: DataSet_teste=pd.read_csv('FuturosEthereum-teste.csv')

preco_real_teste = DataSet_teste.iloc[:, 1:2].values

base_completa = pd.concat((DataSet['Open'], DataSet_teste['Open']), axis = 0)
entradas = base_completa[len(base_completa) - len(DataSet_teste) - NRecurso:]
    ↳values

entradas = entradas.reshape(-1, 1)
entradas = scaler.transform(entradas)
```

```
[26]: DataSetTestLen = len(DataSet_teste)
NPredictions = 90

X_teste = []
for i in range(NRecurso, DataSetTestLen+NRecurso):
    X_teste.append(entradas[i-NRecurso:i, 0])

X_teste = np.array(X_teste)
X_teste = np.reshape(X_teste, (X_teste.shape[0], X_teste.shape[1], 1))

previsoes = regressor.predict(X_teste)
previsoes = scaler.inverse_transform(previsoes)
```

```
[27]: RNN=[]
predictions_teste=X_teste[0].T
predictions_teste=np.reshape(predictions_teste, (predictions_teste.shape[0],
    ↳predictions_teste.shape[1], 1))

predictions_teste[0][NRecurso-1][0]=regressor.predict(predictions_teste)[0][0]
RNN.append(regressor.predict(predictions_teste)[0])

for i in range(NPredictions-1):
    predictions_teste=np.roll(predictions_teste,-1)
    predictions_teste[0][NRecurso-1][0]=regressor.
    ↳predict(predictions_teste)[0][0]
    RNN.append(regressor.predict(predictions_teste)[0])
```

```
RNN = scaler.inverse_transform(RNN)
```

```
print(RNN.mean())
```

```
print(previsoes.mean())
```

```
print(preco_real_teste.mean())
```

2096.7557163208708

2823.6003

3455.175944095238

```
[28]: plt.plot(preco_real_teste, color = 'red', label = 'Preço real')  
plt.plot(previsoes, color = 'blue', label = 'Previsões')  
#plt.plot(RNN, color = 'green', label = 'RNN')
```


```
plt.title('ETHEREUM')
```

```
plt.xlabel('Tempo')
```

```
plt.ylabel('Valor')
```

```
plt.legend()
```

```
plt.show()
```



```
[29]: np.shape(previsoes)
```

```
[29]: (21, 1)
```

[ ]: